

임베디드 IT 및 AI 보안관제 연구 보고서

생체 모방형 분산 신경 구조 기반

홈 CCTV 사생활 영상 유출 및 악성 트래픽 방지를 위한

단말 자율 차단 아키텍처 제안

작성자: 조유정

작성일: 2026 년 9 월 29 일

목차

초록 (Abstract)

1. 서론 (Introduction)

2. 관련 연구 (Related Work)

3. 제안 아키텍처 (Proposed Architecture)

4. 연구 방법 (Methods)

5. 연구 결과 (Results)

6. 논의 (Discussion)

7. 연구의 한계 (Limitations)

8. 결론 (Conclusion)

9. 참고문헌 (References)

부록 A. 연구의 전체 흐름

부록 B. 연구에서 사용하는 주요 용어

초록 (Abstract)

1. 연구 배경 및 목적

홈 CCTV와 IP 카메라는 인터넷에 연결되어 상시 동작하는 IoT 기기로서 외부 공격의 대상이 될 수 있으며, 보안이 충분하지 않을 경우 개인정보 및 영상정보가 유출될 위험이 있다. 또한 IoT 기기가 악성코드에 감염될 경우 봇넷의 일부로 활용되어 DDoS 등의 공격에 악용될 수 있다. 기존의 중앙 서버 또는 클라우드 중심 보안 방식은 외부 서버에서 네트워크 데이터를 분석하는 구조이므로 중앙 서버와의 연결 상태 및 분석 지연에 영향을 받을 수 있다. 따라서 본 연구에서는 중앙 서버의 실시간 판단에 전적으로 의존하지 않고, CCTV 단말 자체에서 1 차적인 네트워크 이상 여부를 판단하고 위험도가 높은 트래픽을 차단하는 분산형 보안 아키텍처를 제안한다.

2. 연구 방법

본 연구는 문어의 신경생물학적 구조에서 영감을 얻었다. 문어는 중앙 신경계뿐만 아니라 팔의 신경계와 신체 구조가 상호작용하면서 감각 및 운동 기능을 처리하는 독특한 구조를 가진다. 본 연구에서는 이러한 특성을 네트워크 시스템에 추상적으로 적용하여 중앙 관제 시스템이 모든 판단을 수행하는 대신, 말단 CCTV 단말에서도 일부 보안 판단과 대응을 수행하는 구조를 설계하였다.

실험에는 UCI Machine Learning Repository에서 제공하는 N-BalIoT 데이터셋을 활용하였다. N-BalIoT는 실제 상용 IoT 장치 9종에서 정상 트래픽과 Mirai 및 BASHLITE에 의해 생성된 악성 트래픽을 수집한 데이터셋이다. 본 연구에서는 총 1,000건의 표본을 추출하고 정상 트래픽 500건과 악성 트래픽 500건으로 구성하였다. 패킷 크기, 발생 빈도, 발생 간격 및 네트워크 연결 특성 등을 이용하여 0.0~1.0 범위의 이상 위험도 점수를 산출하고, 위험도 점수가 0.5 이상일 경우 단말에서 이상 트래픽으로 판단하도록 설정하였다.

3. 연구 결과

실험 결과 정상 트래픽의 평균 이상 위험도 점수는 0.082, 악성 트래픽의 평균 이상 위험도 점수는 0.841로 나타났다. 두 그룹 사이의 평균 위험도 점수 차이는 0.759로 나타났으며, 본 연구에서 설정한 기준값 0.5를 상회하였다. 또한 본 연구에서 구성한 분류 실험에서는 F1-Score 0.981을 기록하였다.

다만 N-BalIoT 데이터셋은 실제 CCTV 영상 유출 데이터를 직접 포함하는 데이터셋이 아니다. 따라서 본 연구의 실험 결과는 실제 영상정보 유출 자체의 탐지 성능을 의미하는 것이 아니라, IoT 악성 네트워크 트래픽에 대한 단말 자율 탐지 가능성을 검증한 결과로 해석해야 한다.

주제어: 임베디드 시스템, IoT 보안, CCTV 보안, AI 보안관제, 네트워크 이상 탐지, Mirai, N-BaIoT, 생체 모방, 분산 보안

1. 서론 (Introduction)

1.1 연구 배경

IoT 기술의 발전으로 CCTV, 도어벨, 웹캠, 온도조절기 등 다양한 장치가 인터넷에 연결되고 있다. 이러한 장치는 사용자에게 편리한 원격 제어와 실시간 정보 제공 기능을 제공하지만, 동시에 네트워크를 통해 외부 공격에 노출될 가능성도 가지고 있다.

특히 IP 카메라와 CCTV는 개인의 생활 공간을 촬영한다는 특성 때문에 보안 사고가 발생할 경우 단순한 기기 장애를 넘어 사생활 침해로 이어질 수 있다. 한국인터넷진흥원(KISA)은 2026년 「IP 카메라 설치·운영 보안 가이드」를 발간하여 IP 카메라의 안전한 설치와 운영을 위한 보안 관리의 필요성을 제시하고 있다.

또한 IoT 장치를 대상으로 한 악성코드 감염 및 봇넷 공격 역시 중요한 보안 문제이다. Kolias et al.은 Mirai 및 관련 IoT 봇넷이 취약한 IoT 장치를 감염시키고 대규모 DDoS 공격에 활용될 수 있음을 분석하였다. 이러한 문제를 고려할 때 CCTV와 같은 IoT 단말에서 네트워크 트래픽을 직접 분석하고 이상 상황에 대응할 수 있는 경량 보안 구조가 필요하다.

1.2 연구 주제 탐색 과정

후보 주제 1: CCTV 영상 자체를 딥러닝으로 분석하는 실시간 영상 보안

영상 프레임 자체를 딥러닝으로 분석하여 이상 상황을 탐지하는 방법을 검토하였다. 그러나 CCTV 단말에서 영상 데이터를 지속적으로 분석하려면 상당한 연산 자원이 필요하며, 저사양 임베디드 환경에서는 CPU, 메모리 및 전력 사용량이 증가할 수 있다. 따라서 본 연구에서는 영상 자체를 분석하는 대신 영상이 네트워크를 통해 전송되는 과정에서 발생하는 트래픽의 이상 여부를 분석하는 방향으로 연구 범위를 설정하였다.

후보 주제 2: 클라우드 중앙 서버 집중형 해킹 분석 시스템

CCTV에서 발생하는 네트워크 데이터를 중앙 서버로 전송하고 서버에서 인공지능을 이용하여 공격을 분석하는 방식을 검토하였다. 이 방식은 중앙 서버에서 상대적으로 높은 연산 능력을 활용할 수 있다는 장점이 있지만, 네트워크 연결이나 서버의 상태에 따라 탐지 및 대응이 지연될 가능성이 있다. 따라서 본

연구에서는 중앙 서버가 모든 보안 판단을 수행하는 구조보다 단말 자체에서 1 차적인 이상 판단을 수행하는 분산형 구조를 연구 대상으로 선정하였다.

후보 주제 3: 생체 모방형 단말 자율 보안 시스템

최종적으로 문어의 독특한 신경생물학적 구조에서 영감을 받아, 중앙 시스템뿐만 아니라 말단 장치에서도 일부 정보 처리와 반응을 수행하는 구조를 네트워크 보안에 적용하는 방식을 선택하였다. 본 연구에서 문어의 구조를 그대로 복제하는 것은 아니며, 중앙 시스템에 모든 판단을 집중하지 않고 말단에서 일부 판단과 대응을 수행한다는 설계 원리를 추상화하여 활용하였다.

1.3 최종 연구 가설

자원 제약적 홈 CCTV 환경에서 경량화된 단말 자율 탐지 규칙을 적용하면 정상 네트워크 트래픽과 악성 네트워크 트래픽 사이에서 0.5 이상의 이상 위험도 점수 차이가 발생하여 중앙 서버의 실시간 판단 없이도 이상 트래픽을 식별하고 차단할 수 있을 것이다.

본 가설에서 독립변수는 네트워크 트래픽의 정상·악성 여부이며, 종속변수는 단말에서 계산되는 이상 위험도 점수 및 이에 따른 차단 여부이다.

1.4 연구 범위

본 연구는 실제 CCTV 장치에서 영상정보를 직접 수집하거나 실제 공격자가 영상을 유출하는 상황을 재현하는 연구가 아니다. 대신 공개 IoT 보안 데이터셋을 이용하여 단말 수준의 네트워크 이상 탐지 및 자율 차단 구조가 구현 가능한지를 확인하는 것을 연구 범위로 설정하였다. 따라서 N-BaIoT 데이터셋은 CCTV 영상 유출의 직접적인 검증 자료가 아니라, 제한된 단말 자율 보안 구조의 네트워크 이상 탐지 가능성을 평가하기 위한 자료로 사용하였다.

2. 관련 연구 (Related Work)

2.1 IoT 봇넷과 Mirai

IoT 기기의 확산은 다양한 네트워크 서비스를 제공하는 동시에 새로운 공격 표면을 형성하였다. Kolias et al.은 Mirai 를 비롯한 IoT 봇넷이 취약한 IoT 장치를 감염시키고 대규모 DDoS 공격에 활용될 수 있음을 분석하였다. 특히 IoT 장치가 인터넷에 지속적으로 연결되어 있다는 특성은 공격자가 대규모 공격 인프라를 구성하는 데 이용될 수 있다. 따라서 IoT 단말에서 발생하는 네트워크 트래픽의 이상 여부를 탐지하고 악성 통신을 차단하는 것은 IoT 보안에서 중요한 방어 요소가 될 수 있다.

2.2 N-BalIoT 데이터셋

Meidan et al.은 IoT 봇넷 공격을 탐지하기 위한 네트워크 기반 이상 탐지 방법인 N-BalIoT 를 제안하였다. N-BalIoT 데이터셋은 실제 상용 IoT 장치 9 종을 대상으로 정상 네트워크 트래픽과 Mirai 및 BASHLITE 감염에 의해 생성된 악성 트래픽을 수집한 데이터셋이다. UCI Machine Learning Repository 에서 제공되는 이 데이터셋은 정상 트래픽과 악성 트래픽을 구분하는 이상 탐지 및 분류 문제에 활용할 수 있다. 본 연구에서는 이러한 특성을 활용하여 정상 트래픽과 악성 트래픽을 비교하고 단말 자율 탐지 규칙의 가능성을 평가하였다.

2.3 문어의 신경생물학적 구조

본 연구의 생체 모방 개념은 Hochner 의 문어 신경생물학 연구에서 착안하였다. Hochner 는 문어가 유연한 신체와 8 개의 팔을 가지고 있으며, 이러한 신체 구조에서 발생하는 복잡한 감각 및 운동 처리 문제를 해결하기 위해 독특한 뇌-신체-행동 관계가 형성되었다고 설명한다. 본 연구에서는 이러한 특성을 네트워크 보안 아키텍처에 직접적으로 복제하는 것이 아니라, 중앙 시스템과 말단 장치가 역할을 분담하는 분산적 처리 개념으로 추상화하였다.

2.4 경량화된 신경형 컴퓨팅

Roy, Jaiswal, Panda 는 뉴로모픽 컴퓨팅과 스파이킹 기반 계산 방식이 이벤트 기반 표현을 활용하여 에너지 효율적인 지능형 컴퓨팅을 구현할 가능성을 설명하였다. 본 연구는 스파이킹 뉴럴 네트워크를 직접 구현한 연구는 아니지만, 자원 제약적인 임베디드 환경에서 모든 데이터를 중앙 서버로 전송하여 처리하는 대신 단말에서 필요한 정보를 처리하고 판단한다는 방향에서 해당 연구의 개념적 시사점을 참고하였다.

2.5 기존 연구와 본 연구의 차이

기존 N-BalIoT 연구는 IoT 장치의 네트워크 트래픽을 분석하여 봇넷 공격을 탐지하는 방법에 초점을 두었다. 반면 본 연구에서는 이러한 IoT 네트워크 이상 탐지 개념을 홈 CCTV 와 같은 자원 제약적 IoT 단말에서 자체적으로 수행하고, 이상 상황 발생 시 단말 수준에서 1 차적으로 통신을 차단하는 분산형 보안 아키텍처로 확장하는 것을 목표로 한다. 또한 문어의 신경생물학적 구조를 생체 모방의 개념적 배경으로 활용하여 중앙 관제와 말단 단말의 역할을 분리하였다.

3. 제안 아키텍처 (Proposed Architecture)

3.1 전체 구조

본 연구에서 제안하는 시스템은 크게 세 계층으로 구성된다.

1 단계: CCTV 단말

CCTV 단말은 외부에서 유입되거나 외부로 전송되는 네트워크 트래픽을 관찰한다. 단말에서는 패킷의 크기, 발생 빈도, 발생 간격 및 네트워크 연결 특성 등의 정보를 이용하여 이상 위험도 점수를 계산한다.

2 단계: 단말 자율 판단 모듈

단말 내부의 탐지 모듈은 계산된 위험도 점수를 설정된 임계값과 비교한다. 위험도 점수가 0.5 미만이면 정상 트래픽으로 판단하고 통신을 허용한다. 반대로 위험도 점수가 0.5 이상이면 이상 트래픽으로 판단하여 차단 대상으로 분류한다.

3 단계: 중앙 관제 시스템

중앙 서버는 모든 패킷을 실시간으로 판단하는 역할이 아니라 여러 CCTV 단말의 보안 상태를 종합적으로 확인하고, 탐지 규칙을 업데이트하거나 장기적인 보안 분석을 수행하는 역할을 담당한다. 이러한 구조에서는 중앙 서버와의 연결이 일시적으로 제한되더라도 단말에서 수행하는 기본적인 이상 탐지 및 차단 기능을 유지할 수 있다.

3.2 생체 모방형 역할 구조

생체 구조	제안 시스템	역할
중앙 신경계	중앙 관제 서버	전체 상태 관리 및 장기 분석
팔의 국소적 신경 처리	CCTV 단말 탐지 모듈	현장에서의 1 차 판단
감각 입력	네트워크 패킷 특징	외부 환경 정보 수집
운동 및 반응	통신 허용/차단	이상 상황에 대한 대응

이 대응 관계는 생물학적 구조를 네트워크 시스템에 그대로 적용한 것이 아니라, 중앙 집중형 처리와 말단 자율 처리를 결합하는 설계 원리를 추상화한 것이다.

3.3 위험도 계산

본 연구에서는 네트워크 트래픽의 이상 정도를 0.0~1.0 범위의 위험도 점수로 표현하였다. 위험도 계산에는 패킷 크기, 단위 시간당 패킷 발생 빈도, 패킷 발생 간격, 연결 특성, 목적지 및 포트 관련 특성을 고려하였다. 각 특징을 정규화한 후 이상 정도를 종합하여 위험도 점수를 산출하였다.

위험도	판단
0.0~0.49	정상 통신으로 판단
0.5~1.0	이상 트래픽으로 판단 및 차단

실제 시스템에 적용하기 위해서는 다양한 정상 사용 환경에서 발생하는 오탐률과 공격 상황에서 발생하는 미탐률을 분석하여 임계값을 추가적으로 최적화할 필요가 있다.

4. 연구 방법 (Methods)

4.1 실험 설계

구분	조건 항목	세부 내용
조작 변수	패킷 종류	정상 통신 트래픽 vs 악성 IoT 트래픽
통제 변수	분석 대상 건수	총 1,000 건
통제 변수	데이터 구성	정상 500 건, 악성 500 건
통제 변수	차단 임계값	0.5
종속 변수	이상 위험도 점수	0.0~1.0
종속 변수	분류 성능	F1-Score

4.2 데이터셋

본 연구에서는 UCI Machine Learning Repository 에서 제공하는 N-BaIoT 데이터셋을 사용하였다. N-BaIoT 는 실제 상용 IoT 장치 9 종에서 정상 트래픽과 Mirai 및 BASHLITE 에 의해 생성된 악성 트래픽을 수집한 데이터셋이다. 데이터셋에는 보안 카메라, 웹캠, 베이비 모니터, 도어벨 등 다양한 IoT 장치의 네트워크 데이터가 포함되어 있어 IoT 네트워크 이상 탐지 연구에 활용할 수 있다. 본 연구에서는 해당 데이터셋에서 총 1,000 건의 표본을 추출하여 정상 트래픽 500 건과 악성 트래픽 500 건으로 구성하였다.

데이터 확인일: 2026 년 9 월 28 일

4.3 데이터 전처리

각 네트워크 트래픽에서 이상 탐지에 활용할 수 있는 특징을 추출하였다. 추출된 특징은 서로 다른 단위를 가지므로 위험도 계산에 앞서 정규화하였다. 이후 각 특징의 이상 정도를 종합하여 0.0~1.0

범위의 이상 위험도 점수를 산출하였다. 본 연구에서는 위험도 점수가 0.5 이상이면 악성 또는 이상 트래픽으로 판단하도록 설정하였다.

4.4 평가 방법

본 연구에서는 정상 트래픽과 악성 트래픽의 평균 위험도 점수 차이를 비교하였다. 또한 분류 결과를 기반으로 F1-Score 를 계산하여 탐지 성능을 평가하였다. F1-Score 는 정밀도(Precision)와 재현율(Recall)의 조화평균으로 정의된다.

$$F1 = 2 \times (Precision \times Recall) / (Precision + Recall)$$

위험도 점수 차이는 다음과 같이 계산하였다.

$$Risk\ Gap = Mean(Risk_malicious) - Mean(Risk_benign)$$

본 연구에서는 정상 트래픽과 악성 트래픽 사이의 위험도 점수 차이가 0.5 이상일 경우 연구 가설이 설정한 기준을 만족하는 것으로 판단하였다.

5. 연구 결과 (Results)

5.1 위험도 점수 분석

데이터 유형	표본 수	평균 이상 위험도 점수	판정 결과
정상 트래픽	500 건	0.082	정상 통과
악성 트래픽	500 건	0.841	자율 차단
두 그룹 간 차이	1,000 건	0.759	기준값 0.5 초과

정상 트래픽의 평균 위험도 점수는 0.082 로 나타났으며, 악성 트래픽의 평균 위험도 점수는 0.841 로 나타났다. 두 그룹의 위험도 점수 차이는 $0.841 - 0.082 = 0.759$ 이다. 따라서 두 그룹 간 위험도 점수 차이는 본 연구에서 설정한 기준값 0.5 보다 높은 것으로 나타났다.

5.2 분류 성능

본 연구의 실험 결과 F1-Score 는 0.981 로 나타났다. 이는 본 연구에서 설정한 위험도 계산 방식과 1,000 건의 실험 표본을 기준으로 계산된 결과이다. 따라서 해당 값은 N-BaloT 원 논문에서 보고된 성능값과 동일한 것이 아니며, 본 연구에서 별도로 수행한 실험의 결과이다.

5.3 예외 사례

악성 트래픽 중 일부 표본은 위험도 점수가 설정된 차단 임계값에 도달하지 않아 탐지되지 않았다. 본 연구에서는 총 9 건의 악성 트래픽이 상대적으로 낮은 위험도 점수를 나타낸 것으로 확인하였다. 이러한 미탐지 사례는 정상 트래픽과 악성 트래픽 사이에 네트워크 특징이 유사한 경우 단순한 위험도 규칙만으로 정확한 구분이 어려울 수 있음을 보여준다. 따라서 실제 시스템에서는 단일 특징이나 단일 임계값에만 의존하기보다 시간적 패턴, 연결 대상, 패킷 흐름 및 장치별 정상 행동 프로파일 등을 함께 고려할 필요가 있다.

5.4 가설 검증

본 연구의 가설은 자원 제약적 홈 CCTV 환경에서 경량화된 단말 자율 탐지 규칙을 적용하면 정상 네트워크 트래픽과 악성 네트워크 트래픽 사이에서 0.5 이상의 이상 위험도 점수 차이가 발생할 것이라는 것이었다. 실험 결과 위험도 점수 차이는 0.759로 나타났으며 이는 설정한 기준값 0.5보다 높은 값이다. 따라서 본 연구에서 설정한 실험 조건과 데이터 표본에 한하여 가설의 기준을 충족하는 결과가 확인되었다. 다만 이 결과를 실제 CCTV 영상 유출 탐지 성능으로 확대하여 해석하는 것은 적절하지 않으며, 실제 CCTV 환경에서의 추가적인 검증이 필요하다.

6. 논의 (Discussion)

6.1 연구 결과의 의미

본 연구의 실험 결과는 IoT 네트워크 트래픽의 정상 여부를 단말 수준에서 판단할 가능성을 보여준다. 특히 모든 데이터를 중앙 서버로 전달한 후 분석하는 방식과 달리 단말 자체에서 1차적인 위험도 계산과 차단 여부를 판단할 경우, 중앙 서버의 실시간 응답에 대한 의존도를 낮출 수 있다. 이는 홈 CCTV와 같이 네트워크 연결이 필수적이고 개인정보를 지속적으로 처리하는 장치에서 로컬 수준의 방어 기능을 제공하는 데 활용될 수 있다.

6.2 생체 모방 구조의 의의

본 연구에서는 문어의 신경생물학적 특성을 네트워크 보안 아키텍처의 개념적 모델로 활용하였다. 문어의 신경계는 중앙 신경계와 신체의 말단 구조가 상호작용하는 독특한 조직을 가지고 있으며, 복잡한 감각 및 운동 기능을 중앙 시스템의 단일한 제어만으로 설명하기 어렵다는 특징을 가진다. 본 연구에서는 이러한 특성을 중앙 관제 서버는 전체 시스템 관리 및 장기적인 분석을 담당하고 CCTV 단말은 현장에서 네트워크 이상 여부를 판단하고 1차적으로 차단하는 구조로 추상화하였다.

6.3 임베디드 IT 관점의 의의

본 연구는 단말 자체에서 네트워크 트래픽을 분석하고 대응하는 구조를 제안한다는 점에서 임베디드 IT와 정보보안의 융합 가능성을 보여준다. CCTV와 같은 IoT 장치는 중앙 서버와 비교하면 상대적으로 제한된 CPU, 메모리 및 전력 자원을 가지고 있기 때문에 복잡한 인공지능 모델을 그대로 탑재하기 어려울 수 있다. 따라서 실제 임베디드 환경에서는 모든 데이터를 고성능 중앙 서버에서 처리하는 방식뿐 아니라, 단말에서 간단한 특징 추출과 1차적인 판단을 수행하고 필요한 정보만 중앙 서버로 전달하는 엣지 보안 구조를 고려할 수 있다.

6.4 실제 CCTV 보안 시스템으로의 확장

실제 CCTV 환경에 적용하기 위해서는 정상적인 영상 스트리밍 패턴을 수집하여 정상 행동 프로파일을 구축하고, 정상적인 원격 접속과 공격자가 수행하는 비정상적인 영상 접근을 구분할 수 있는 데이터가 필요하다. 또한 실제 CCTV 장치 또는 임베디드 보드에서 제안된 탐지 모듈을 실행하여 CPU 사용량, 메모리 사용량, 전력 소비량 및 탐지 지연시간을 측정해야 한다. 중앙 서버와 연결되지 않은 상태에서도 기본적인 차단 기능을 유지할 수 있는 로컬 방화벽 또는 네트워크 필터링 구조를 구현하는 것도 필요하다.

7. 연구의 한계 (Limitations)

7.1 데이터셋의 한계

N-BalIoT는 IoT 봇넷 공격을 탐지하기 위한 데이터셋이며 실제 CCTV 영상정보 유출 데이터를 직접 포함하지 않는다. 따라서 본 연구의 실험 결과를 실제 CCTV 영상 유출 방지 성능으로 직접 일반화하는 데에는 한계가 있다. 본 연구의 실험 결과는 IoT 악성 네트워크 트래픽에 대한 단말 자율 탐지 가능성을 평가한 것으로 해석해야 한다.

7.2 실제 하드웨어 환경의 한계

본 연구는 소프트웨어 기반 데이터 분석을 중심으로 수행되었다. 따라서 실제 CCTV 장치에서 발생할 수 있는 CPU 및 메모리 사용량, 전력 소비, 네트워크 지연 및 패킷 처리량 등의 하드웨어 변수를 충분히 검증하지 못했다.

7.3 표본 수의 한계

본 연구에서는 총 1,000 건의 표본을 사용하였다. 표본 수와 데이터 구성이 제한되어 있으므로 다양한 CCTV 모델, 네트워크 환경 및 공격 유형에서 동일한 결과가 나타난다고 일반화하기 어렵다.

7.4 임계값의 한계

본 연구에서는 위험도 0.5 를 차단 기준으로 설정하였다. 그러나 실제 운영 환경에서는 정상적인 원격 접속이나 네트워크 상태 변화로 인해 정상 트래픽이 높은 위험도로 판단될 가능성이 있다. 따라서 실제 서비스에서는 오탐률과 미탐률을 동시에 고려하여 최적의 차단 임계값을 결정해야 한다.

7.5 영상 유출 탐지 검증의 한계

본 연구는 실제 영상정보 유출 공격을 직접 수행하거나 실제 CCTV 영상 데이터를 이용하여 유출 여부를 검증하지 않았다. 따라서 향후에는 실제 IP 카메라 환경에서 정상 영상 스트리밍, 정상적인 원격 접속, 비정상적인 외부 접속 및 영상 데이터 유출 상황을 각각 구성하여 추가적인 검증이 필요하다.

8. 결론 (Conclusion)

본 연구에서는 문어의 독특한 신경생물학적 구조에서 영감을 얻어 중앙 관제 서버에 모든 보안 판단을 의존하지 않고, 홈 CCTV 와 같은 IoT 단말 자체에서 네트워크 이상 여부를 판단하고 차단하는 단말 자율 보안 아키텍처를 제안하였다.

실험에서는 UCI Machine Learning Repository 의 N-BaIoT 데이터셋을 활용하여 정상 트래픽 500 건과 악성 트래픽 500 건, 총 1,000 건을 분석하였다. 실험 결과 정상 트래픽의 평균 이상 위험도 점수는 0.082, 악성 트래픽의 평균 이상 위험도 점수는 0.841 로 나타났으며 두 그룹 사이의 위험도 점수 차이는 0.759 로 나타났다. 또한 본 연구에서 구성한 분류 실험에서는 F1-Score 0.981 을 기록하였다.

이 결과는 본 연구에서 설정한 실험 환경에서 단말 수준의 경량화된 위험도 분석을 통해 정상 트래픽과 악성 IoT 트래픽을 구분할 가능성을 보여준다. 그러나 N-BaIoT 데이터셋은 실제 CCTV 영상 유출 데이터를 직접 포함하지 않기 때문에 본 결과를 실제 사생활 영상 유출 차단 성능으로 직접 해석해서는 안 된다.

본 연구의 핵심적인 의의는 IoT 단말이 중앙 서버의 판단을 기다리는 수동적인 장치가 아니라, 자체적으로 네트워크 상태를 분석하고 이상 상황에 1 차적으로 대응하는 능동적인 보안 구성요소가 될 수 있다는 아키텍처를 제안했다는 점에 있다.

향후 연구에서는 실제 CCTV 또는 IP 카메라 장치를 대상으로 정상 영상 스트리밍과 비정상 영상 유출 트래픽을 직접 수집하고, 실제 임베디드 보드에서 제안된 탐지 모듈을 구현할 필요가 있다. 또한 CPU 사용량, 메모리 사용량, 전력 소비량 및 탐지 지연시간을 함께 측정하여 자원 제약적인 CCTV 환경에서 제안 구조의 실현 가능성을 검증할 필요가 있다.

9. 참고문헌 (References)

- [1] Meidan, Y., Bohadana, M., Mathov, Y., Mirsky, Y., Shabtai, A., Breitenbacher, D., & Elovici, Y. (2018). N-BaloT—Network-Based Detection of IoT Botnet Attacks Using Deep Autoencoders. *IEEE Pervasive Computing*, 17(3), 12–22. <https://doi.org/10.1109/MPRV.2018.03367731>
- [2] Meidan, Y., Bohadana, M., Mathov, Y., Mirsky, Y., Breitenbacher, D., & Shabtai, A. (2018). N-BaloT Dataset to Detect IoT Botnet Attacks. UCI Machine Learning Repository. <https://doi.org/10.24432/C5RC8J>
- [3] Hochner, B. (2012). An Embodied View of Octopus Neurobiology. *Current Biology*, 22(20), R887–R892. <https://doi.org/10.1016/j.cub.2012.09.001>
- [4] Roy, K., Jaiswal, A., & Panda, P. (2019). Towards Spike-Based Machine Intelligence with Neuromorphic Computing. *Nature*, 575(7784), 607–617. <https://doi.org/10.1038/s41586-019-1677-2>
- [5] Kolias, C., Kambourakis, G., Stavrou, A., & Voas, J. (2017). DDoS in the IoT: Mirai and Other Botnets. *Computer*, 50(7), 80–84. <https://doi.org/10.1109/MC.2017.201>
- [6] 한국인터넷진흥원. (2026). IP 카메라 설치·운영 보안 가이드. KISA 보호나라&KrCERT/CC.

부록 A. 연구의 전체 흐름

연구 문제 정의 → 홈 CCTV 및 IoT 보안 위협 조사 → 기존 중앙 서버 중심 보안 방식의 한계 분석 → 문어의 분산적 신경 구조에서 생체 모방 개념 도출 → 단말 자율 탐지 아키텍처 설계 → N-BaloT 공개 데이터셋 선정 → 정상/악성 트래픽 1,000 건 추출 → 네트워크 특징 추출 및 정규화 → 이상 위험도 점수 계산 → 위험도 0.5 기준 자율 차단 → 위험도 점수 차이 및 F1-Score 측정 → 단말 자율 탐지 가능성 평가 → 실제 CCTV 환경 적용 가능성 및 한계 분석

부록 B. 연구에서 사용하는 주요 용어

용어	의미
IoT	인터넷에 연결되어 데이터를 주고받는 사물인터넷 장치
IP Camera	네트워크를 통해 영상 데이터를 전송하는 카메라

Mirai	IoT 장치를 감염시켜 봇넷으로 활용한 대표적인 악성코드
Botnet	공격자에 의해 원격으로 제어되는 감염 장치들의 집합
Data Exfiltration	시스템 내부의 데이터를 외부로 무단 전송하는 행위
N-Balot	IoT 봇넷 공격 탐지를 위한 공개 네트워크 트래픽 데이터셋
Edge/단말 보안	중앙 서버가 아닌 데이터가 발생하는 단말에서 수행하는 보안 처리
이상 탐지	정상적인 행동 패턴과 다른 비정상적인 행동을 탐지하는 방법
F1-Score	정밀도와 재현율의 조화평균을 이용한 분류 성능 평가 지표
위험도 점수	네트워크 트래픽의 이상 정도를 0~1 범위로 표현한 본 연구의 지표
생체 모방	생물학적 구조나 원리에서 영감을 얻어 기술 시스템을 설계하는 방법